Pengaruh Penambahan Blok Konvolusi Ketiga pada 1D CNN untuk Klasifikasi Detak Jantung EKG MIT-BIH

Martin Manullang
Program Studi Teknik Biomedis
Institut Teknologi Sumatera (ITERA)
Lampung Selatan, Indonesia
NIM 123123123

***Abstrak*—Laporan ini membandingkan model 1D *convolutional neural network* (CNN) dua blok konvolusi (CNN-2) dengan varian tiga blok konvolusi (CNN-3) untuk klasifikasi lima kelas detak jantung (N, S, V, F, Q) pada *ECG Heartbeat Categorization Dataset* turunan MIT-BIH. Kedua model dilatih dengan resep identik (Adam, laju belajar 0,001, *batch* 128, 10 *epoch*) dan diulang pada lima *seed*. CNN-3 menambah 10,6% parameter dan 19% waktu latih. CNN-3 belajar lebih cepat dan mencapai *loss* latih lebih rendah. Median F1 makro CNN-3 lebih tinggi (0,881 vs 0,869), terutama karena *recall* kelas minoritas S dan F naik. Namun, satu dari lima *run* CNN-3 mengalami penurunan tajam pada *epoch* terakhir sehingga rata-rata F1 makro kedua model praktis sama (0,871 ± 0,029 vs 0,870 ± 0,006; uji-*t* berpasangan $p = 0{,}91$). Dengan protokol pelatihan tanpa validasi dan *early stopping*, penambahan blok ketiga belum memberikan peningkatan yang konsisten.**

***Kata Kunci*—Elektrokardiogram, klasifikasi aritmia, 1D CNN, MIT-BIH, deep learning**

I. Pendahuluan

Elektrokardiogram (EKG) adalah pemeriksaan non-invasif utama untuk mendeteksi aritmia. Analisis manual rekaman panjang memakan waktu, sehingga klasifikasi detak otomatis banyak diteliti. CNN satu dimensi (1D CNN) cocok untuk tugas ini karena dapat mempelajari ciri morfologi detak langsung dari sinyal mentah tanpa ekstraksi fitur manual [1], [2].

Pada praktikum Pertemuan 9 telah dibangun 1D CNN sederhana dengan dua blok konvolusi (CNN-2) pada dataset Kachuee dkk. [3]. Latihan di akhir notebook menyarankan penambahan blok konvolusi ketiga. Pertanyaan yang ingin dijawab laporan ini: *apakah blok ketiga meningkatkan kinerja klasifikasi, khususnya pada kelas minoritas, dan berapa biayanya?* Karena hasil satu kali pelatihan dapat berbeda hanya karena inisialisasi acak, setiap model dilatih pada lima *seed* dan dibandingkan secara berpasangan.

II. Dataset dan Metode

A. Dataset

Dataset yang dipakai adalah *ECG Heartbeat Categorization Dataset* [3], yang diturunkan dari MIT-BIH Arrhythmia Database [4], [5]. Setiap sampel adalah satu detak yang disejajarkan pada puncak R, dicuplik ulang ke 125 Hz, dinormalisasi ke [0, 1], dan dipotong/diisi nol hingga 187 titik (≈1,5 s). Label mengikuti lima kelas AAMI EC57 [6]: N (normal), S (ektopik supraventrikular), V (ektopik ventrikular), F (*fusion*), dan Q (tak terklasifikasi, termasuk detak *paced*). Pembagian latih/uji mengikuti file asli: 87.554 detak latih dan 21.892 detak uji. Distribusinya sangat tidak seimbang: kelas N mencakup 82,8% data uji, sedangkan kelas F hanya 162 detak (0,7%).

TABEL I
Arsitektur dan ukuran keluaran tiap lapisan (kanal × panjang)

Lapisan	CNN-2	CNN-3
Masukan	1 × 187	1 × 187
Blok 1: Conv(16) + Pool	16 × 93	16 × 93
Blok 2: Conv(32) + Pool	32 × 46	32 × 46
Blok 3: Conv(64) + Pool	—	64 × 23
Flatten	1.472	1.472
Linear + ReLU	64	64
Linear (keluaran)	5	5
Jumlah parameter	97.285	107.589
Medan reseptif blok akhir	16 sampel (0,13 s)	36 sampel (0,29 s)

B. Arsitektur Model

Tabel I merangkum kedua arsitektur. CNN-2 identik dengan model pada notebook: dua blok `Conv1d` (kernel 5, *padding* 2) + ReLU + `MaxPool1d(2)` dengan 16 dan 32 filter, diikuti lapisan *fully connected* 64 unit dan keluaran 5 kelas. CNN-3 menambahkan blok ketiga dengan 64 filter. Karena blok ketiga menggandakan jumlah kanal sekaligus membagi dua panjang sinyal, ukuran vektor hasil *flatten* tetap 1.472 ($32 \times 46 = 64 \times 23$), sehingga tambahan parameter hanya berasal dari konvolusi ketiga (10.304 parameter, +10,6%). Perbedaan utamanya adalah medan reseptif: satu fitur pada blok konvolusi terakhir CNN-3 melihat 36 sampel (0,29 s), sedangkan CNN-2 hanya 16 sampel (0,13 s), sedikit di atas lebar kompleks QRS normal.

TABEL II
Kinerja pada data uji setelah 10 *epoch* (rerata ± simpangan baku, 5 *seed*)

Metrik	CNN-2	CNN-3
Akurasi (%)	97,65 ± 0,12	97,43 ± 1,13
F1 makro	0,870 ± 0,006	0,871 ± 0,029
Waktu latih (s)	42,2 ± 3,0	50,2 ± 1,8

C. Protokol Pelatihan dan Evaluasi

Kedua model dilatih dengan resep notebook tanpa modifikasi: *cross-entropy loss* tanpa pembobotan kelas, optimizer Adam [7] dengan laju belajar 0,001, ukuran *batch* 128 dengan pengacakan, selama 10 *epoch*. Implementasi memakai PyTorch 2.14.1 [8] pada GPU Apple Silicon (MPS). Setiap model dilatih dengan *seed* {42, 0, 1, 2, 3}. *Seed* yang sama menghasilkan urutan *batch* yang sama untuk kedua model, sehingga selisih kinerja dapat dibandingkan berpasangan per *seed*.

Model hasil *epoch* ke-10 dievaluasi pada data uji. Karena data tidak seimbang, metrik utama adalah F1 makro, yaitu rata-rata F1 kelima kelas dengan bobot sama:

$$\mathrm{F1}_{\mathrm{makro}} = \frac{1}{K}\sum_{k=1}^{K}\frac{2P_kR_k}{P_k+R_k}, \quad K=5, \tag{1}$$

dengan P_k dan R_k presisi dan *recall* kelas k. Akurasi tetap dilaporkan sebagai pembanding. Kinerja pada data uji juga dicatat setiap *epoch* untuk kurva belajar, tetapi tidak dipakai memilih *epoch* atau model. Hasil dilaporkan sebagai rerata ± simpangan baku lima *seed*. Signifikansi selisih diuji dengan uji-t berpasangan.

III. Hasil

A. Kinerja Keseluruhan

Tabel II menunjukkan bahwa rerata akurasi dan F1 makro kedua model hampir sama, tetapi simpangan baku CNN-3 jauh lebih besar. Selisih berpasangan F1 makro (CNN-3 − CNN-2) adalah +0,001 ± 0,024 ($t(4) = 0{,}12$; $p = 0{,}91$), dan selisih akurasi −0,22 ± 1,05 poin persen ($t(4) = -0{,}46$; $p = 0{,}67$). CNN-3 unggul F1 makro pada 4 dari 5 *seed*, dan median F1 makronya lebih tinggi (0,881 vs 0,869). Namun, pada *seed* 0 CNN-3 turun tajam (F1 makro 0,821; akurasi 95,44%), dan satu *run* ini cukup untuk menghapus keunggulan rata-ratanya. Tanpa *seed* 0, rerata F1 makro menjadi 0,884 (CNN-3) vs 0,872 (CNN-2). Biaya CNN-3 adalah waktu latih 19% lebih lama.

B. Kinerja per Kelas

Tabel III dan Gambar 1 memperlihatkan bahwa perbedaan kedua model terletak pada kelas minoritas. CNN-3 menaikkan *recall* kelas S dari 0,662 menjadi 0,720 dan kelas F dari 0,626 menjadi 0,669. Akan tetapi, presisi kelas S turun dari 0,888 menjadi 0,827 dengan simpangan baku 0,186, sehingga F1 kelas S tidak berubah. Kelas N, V, dan Q sudah di atas 0,93 untuk kedua model dan praktis tidak berubah.

Pola ini juga tampak pada *confusion matrix seed* 42 (Gambar 2). Kesalahan terbesar kedua model adalah detak S dan F yang ditebak sebagai N. CNN-3 mengurangi kesalahan S → N (169 → 152) dan F → N/V, tetapi menambah kesalahan V → N (66 → 98) dan Q → N (19 → 71). Artinya, sebagian peningkatan pada kelas minoritas dibayar dengan kesalahan baru di kelas lain.

TABEL III
Presisi, *recall*, dan F1 per kelas pada data uji (rerata ± simpangan baku, 5 *seed*)

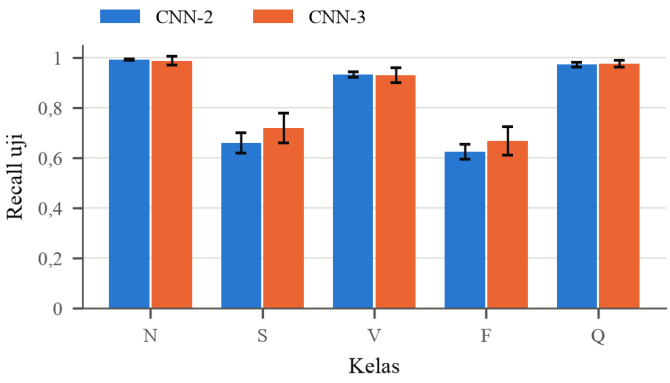
Kelas (*n*)	Model	Presisi	Recall	F1
N (18.118)	CNN-2	0,983 ± 0,002	0,993 ± 0,002	0,988 ± 0,001
	CNN-3	0,985 ± 0,005	0,988 ± 0,018	0,986 ± 0,007
S (556)	CNN-2	0,888 ± 0,040	0,662 ± 0,040	0,757 ± 0,019
	CNN-3	0,827 ± 0,186	0,720 ± 0,058	0,754 ± 0,076
V (1.448)	CNN-2	0,934 ± 0,009	0,934 ± 0,010	0,934 ± 0,004
	CNN-3	0,939 ± 0,059	0,931 ± 0,029	0,933 ± 0,021
F (162)	CNN-2	0,783 ± 0,060	0,626 ± 0,029	0,694 ± 0,012
	CNN-3	0,755 ± 0,126	0,669 ± 0,056	0,701 ± 0,043
Q (1.608)	CNN-2	0,980 ± 0,010	0,973 ± 0,009	0,977 ± 0,003
	CNN-3	0,986 ± 0,009	0,977 ± 0,014	0,981 ± 0,005

C. Dinamika Pelatihan

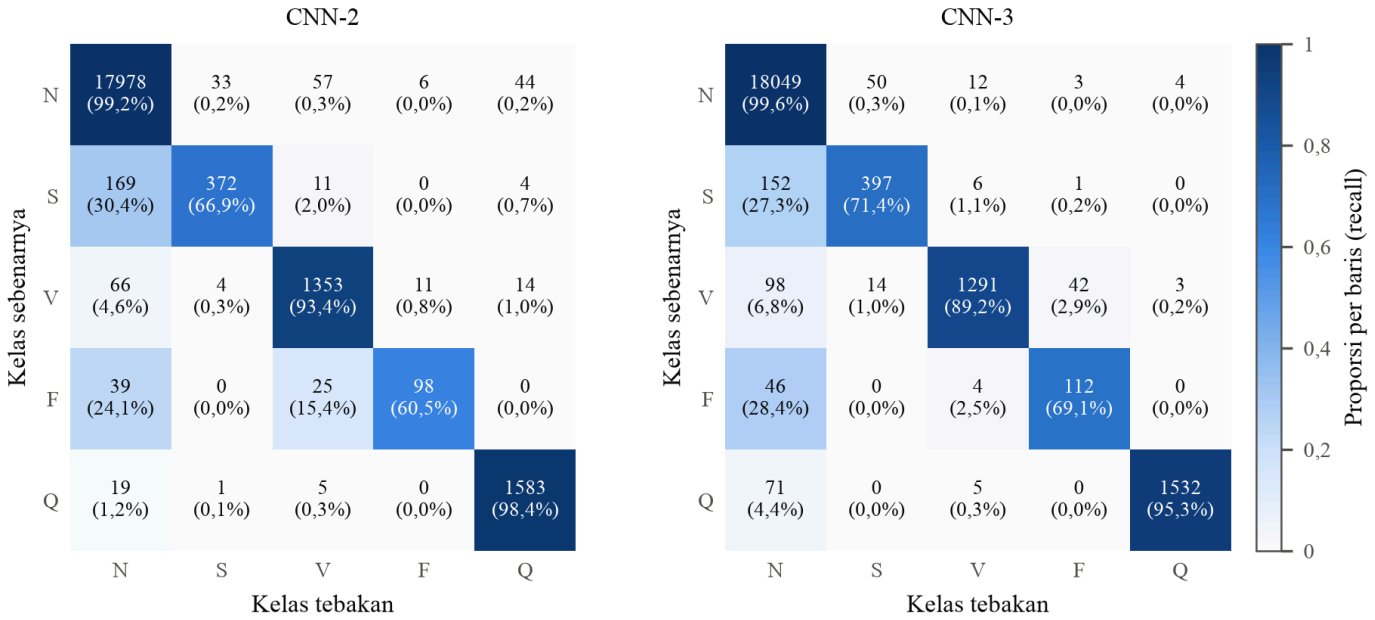
Gambar 3 menunjukkan bahwa CNN-3 belajar lebih cepat. *Loss* latihnya lebih rendah di setiap *epoch* (0,053 vs 0,072 pada *epoch* 10), dan F1 makro ujinya sudah 0,718 setelah *epoch* pertama (CNN-2: 0,683). Pada *epoch* 6 F1 makro CNN-3 mencapai 0,874, yaitu nilai yang tidak pernah dicapai rerata CNN-2 selama 10 *epoch*. Akan tetapi, kurva F1 makro CNN-3 mendatar dan sedikit turun setelah *epoch* 8 (0,880 → 0,871) dan pitanya melebar, sedangkan CNN-2 masih naik hingga akhir.

IV. Pembahasan

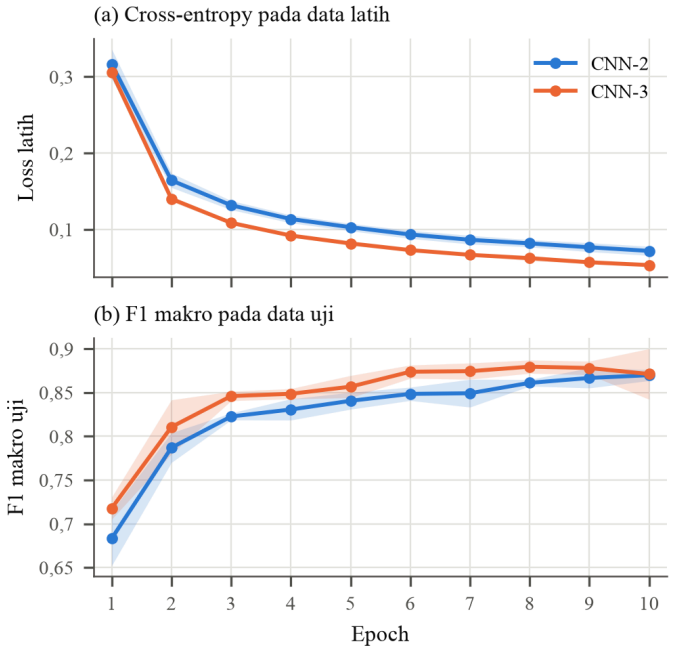
Hasil ini menunjukkan bahwa kapasitas tambahan CNN-3 *berguna*: model lebih cepat menemukan pola dan lebih sering mengenali detak S dan F. Salah satu penjelasan yang mungkin adalah medan reseptif yang lebih lebar (0,29 s). Detak S sering hanya berbeda dari N pada gelombang P dan jarak R-R, ciri yang berada di luar kompleks QRS, sehingga fitur dengan konteks lebih panjang dapat membantu. Dugaan ini belum diuji secara langsung dalam laporan ini.



Gambar 1. Rerata *recall* per kelas pada data uji. Garis galat menunjukkan simpangan baku lima *seed*.



Gambar 2. *Confusion matrix* data uji untuk *seed* 42. Angka atas adalah jumlah detak; angka dalam kurung adalah proporsi terhadap jumlah kelas sebenarnya (*recall* pada diagonal).



Gambar 3. Kurva belajar: (a) *loss* latih dan (b) F1 makro data uji per *epoch*. Garis adalah rerata dan pita adalah ± simpangan baku lima *seed*.

Masalahnya ada pada *kestabilan*. Pada *seed* 0, F1 makro CNN-3 adalah 0,865 pada *epoch* 9 lalu turun ke 0,821 pada *epoch* 10. Pada *epoch* 10, model ini menebak 448 detak N sebagai S, sehingga presisi kelas S hanya 0,50 walaupun *recall*-nya 0,82. Artinya, batas keputusan bergeser ke arah kelas S dalam satu *epoch*. Kemungkinan penyebabnya adalah ketidakseimbangan data: kelas S dan F hanya menyumbang sedikit *gradien*, sehingga posisi batas keputusannya sensitif terhadap beberapa langkah optimisasi terakhir. Karena protokol notebook selalu mengambil model *epoch* terakhir, ketidakstabilan ini langsung terlihat sebagai hasil akhir.

Laporan ini memiliki beberapa keterbatasan. Pertama, lima *seed* hanya cukup untuk menunjukkan arah, bukan menyimpulkan signifikansi. Kedua, tidak ada data validasi, sehingga tidak dapat dilakukan *early stopping* atau pemilihan *epoch* tanpa mengintip data uji. Ketiga, pembagian latih/uji dataset ini dilakukan per detak, bukan per pasien, sehingga detak dari pasien yang sama dapat muncul di kedua bagian. Kinerja pada pasien baru (*inter-patient*) biasanya jauh lebih rendah [9]. Keempat, operasi pada GPU tidak sepenuhnya deterministik, sehingga pengulangan dengan *seed* yang sama dapat sedikit berbeda.

V. Kesimpulan

Penambahan blok konvolusi ketiga (64 filter) pada 1D CNN menambah 10,6% parameter dan 19% waktu latih. CNN-3 belajar lebih cepat, mencapai *loss* latih lebih rendah, dan cenderung menaikkan *recall* kelas minoritas S dan F, sehingga median F1 makronya lebih tinggi (0,881 vs 0,869). Namun, dengan resep pelatihan yang sama (10 *epoch* tetap, tanpa validasi), hasil CNN-3 kurang stabil, dan secara rata-rata keunggulannya tidak signifikan (p = 0,91). Jadi, model CNN-2 dari notebook sudah merupakan titik awal yang kuat, dan blok ketiga baru layak dipakai jika disertai pemilihan model berbasis data validasi (*early stopping*). Langkah lanjut yang disarankan adalah: (1) memisahkan data validasi dari data latih dan menerapkan *early stopping*, (2) memakai *class-weighted loss* untuk kelas S dan F, dan (3) mengevaluasi ulang dengan pembagian *inter-patient*.

Kode eksperimen (`eksperimen_cnn3.py`), pembuat gambar (`buat_gambar.py`), dan hasil mentah (`hasil/hasil.json`) tersedia di folder `pertemuan-09/laporan/` repositori praktikum.

Daftar Pustaka

[1] S. Kiranyaz, T. Ince, and M. Gabbouj, "Real-Time Patient-Specific ECG Classification by 1-D Convolutional Neural Networks," *IEEE Transactions on Biomedical Engineering*, vol. 63, no. 3, pp. 664–675, 2016, doi: 10.1109/TBME.2015.2468589.

[2] A. Y. Hannun *et al.*, "Cardiologist-level arrhythmia detection and classification in ambulatory electrocardiograms using a deep neural network," *Nature Medicine*, vol. 25, no. 1, pp. 65–69, 2019, doi: 10.1038/s41591-018-0268-3.

[3] M. Kachuee, S. Fazeli, and M. Sarrafzadeh, "ECG Heartbeat Classification: A Deep Transferable Representation," in *Proc. IEEE Int. Conf. Healthcare Informatics (ICHI)*, New York, NY, USA, 2018, pp. 443–444. doi: 10.1109/ICHI.2018.00092.

[4] G. B. Moody and R. G. Mark, "The impact of the MIT-BIH Arrhythmia Database," *IEEE Engineering in Medicine and Biology Magazine*, vol. 20, no. 3, pp. 45–50, 2001, doi: 10.1109/51.932724.

[5] A. L. Goldberger *et al.*, "PhysioBank, PhysioToolkit, and PhysioNet: Components of a New Research Resource for Complex Physiologic Signals," *Circulation*, vol. 101, no. 23, pp. e215–e220, 2000, doi: 10.1161/01.CIR.101.23.e215.

[6] Association for the Advancement of Medical Instrumentation, "Testing and reporting performance results of cardiac rhythm and ST segment measurement algorithms." 2012.

[7] D. P. Kingma and J. Ba, "Adam: A Method for Stochastic Optimization," in *Proc. Int. Conf. Learning Representations (ICLR)*, 2015.

[8] A. Paszke *et al.*, "PyTorch: An Imperative Style, High-Performance Deep Learning Library," in *Advances in Neural Information Processing Systems 32 (NeurIPS)*, 2019, pp. 8024–8035.

[9] P. de Chazal, M. O'Dwyer, and R. B. Reilly, "Automatic classification of heartbeats using ECG morphology and heartbeat interval features," *IEEE Transactions on Biomedical Engineering*, vol. 51, no. 7, pp. 1196–1206, 2004, doi: 10.1109/TBME.2004.827359.